

HW3 — Plot

1151 暑修 生醫資訊程式設計 — R 軌

課程：生醫資訊程式設計 (1151 暑修) —— R 軌 (鍾翊方老師，上午)

助教：黃志榕 email isly29@gmail.com

對應堂次：第 3 堂 (7/28 二) Plot

資料檔 SRBCT_train.txt 2308 genes × 63 samples 前 2 欄為 Image Id / Gene Description

繳交 2 個檔案 — 程式碼 {姓名}_hw_3.R 結果 PDF {姓名}_hw_3.pdf (含執行結果、圖、AI Prompt 兩檔皆須含姓名 (無姓名 -20) ; 相對路徑讀檔 (絕對路徑 -10

截止：上課日 +1 週的週五 24:00 ; 逾一週扣 10 分 ; 暑修總封頂 9/30 24:00 (確切日以 Classroom 公告為準)

提問：請於 Google Classroom 公開發問

AI 政策：允許用 AI 作答，但須附上你的 prompt

主題目 (佔 90%)

1. Read the data from SRBCT_train.txt
2. Normalize data by each **row** let values b/w 0~1
3. Scatter plots for Image ID 770394, 814260, 491565
4. Scatter plots for 770394 vs 236282 , 及 812105 vs 784224
5. 不同 category 的樣本用不同顏色、符號、legend 區分

提示 (投影片原附)

```
nor <- function(x) {                                # ← 要先定義函式，才能在下面用
  min.x <- min(x)
  max.x <- max(x)
  (x - min.x) / (max.x - min.x)
}
```

```
data_SRBCT <- read.delim("SRBCT_train.txt")
data1      <- as.matrix(data_SRBCT[, -c(1:2)])
name1      <- data_SRBCT[, 1]
data1_nor  <- t(apply(data1, 1, nor))
plot(data1_nor[which(name1 == "770394"), ,])
```

投影片上 nor() 印在後面，但實際執行時必須先定義函式再呼叫，否則會出現 could not find function "nor"

加分題 (合計佔 10% , 依繳交狀況酌予加分)

加分題皆為額外加分，非必做。只用該堂教過的函式，難在把圖畫對、畫整齊，不在冷僻語法。

加分題 A 最難)

用 normalize 後的 SRBCT_train.txt，分別計算每個 gene 在 **EWS / BL / NB / RMS** 四組樣本各自的平均表現量，接著找出符合下列三種表現樣式的 genes

1. **BL-low pattern** BL 組的平均低於 EWS NB RMS 三組各自的平均
2. **EWS-NB-low pattern** EWS 與 NB 兩組的平均，低於 BL 與 RMS 兩組的平均
3. **EWS-RMS-low pattern** EWS 與 RMS 兩組的平均，低於 BL 與 NB 兩組的平均

每一種 pattern 都以**低表現的那一組 (或兩組)** 為 **target**、其餘合併為 others 對每個 gene 計算 **SNR**，並挑出 **SNR 值最小的那個 gene**

接著針對每一種 pattern

畫出所選 gene 在**全部樣本**上的 normalized 表現量 scatter plot

用**四種不同顏色 + 四種不同符號**分別代表 EWS / BL / NB / RMS 每組各自一種顏色與一種符號)

提示

```
# read.delim() 會把欄名的 "-" 自動換成 "." EWS-T1 -> EWS.T1
# 所以要用 "." 或「只抓開頭英文字母」的寫法來切組別：
group <- sub("^(A-Za-z)+).*", "\\1", colnames(data1)) # EWS.T1 -> EWS
table(group) # 應為 BL 8 / EWS 23 / NB 12 / RMS 20
```

```
mean_EWS <- rowMeans(data1_nor[, group == "EWS"])
# SNR = (mean(target) - mean(others)) / (sd(target) + sd(others))
```

四組樣本數為 **EWS 23 / RMS 20 / NB 12 / BL 8** (共 63 先跑一次 `table(group)` 確認是這四組、數字對得上再往下做 —— 若你用 `sub("-.*", "", ...)` 之類針對 `-` 的寫法，在 R 裡會完全切不出組別 (每個樣本各自成一組)，後面全錯。三種 pattern 在本份資料下都找得到 gene 若某個 pattern 算出 0 個，多半是分組或比較方向寫反了。

加分題 B

用 `par(mfrow = ...)` 把主題目第 3 4 點的四張 scatter plot 排成一張組合圖，但不要用方方正正的 2×2 等分排版。請自己設計版面，例如：

左上一張比較寬，右上與左下是扁平的，右下留白不畫
或是「一張主圖 + 三張小圖」的配置

提示 `layout()` 搭配矩陣可以做出不等分的版面；`par(mfrow)` 也可以配合 `widths / heights` 的概念調整長寬比。重點是版面要有變化，不是把四張圖平均塞進 2×2

加分題 C

改用 `cycleData_peak.txt` 這份資料 (酵母菌細胞週期，800 genes × 77 個時間點，最後一欄 peak 是該 gene 的高峰期別)。

1. peak 欄共有 **5 種期別** G1 / G2/M / S/G2 / M/G1 / S
2. 從**每一種期別**中，自己挑一個沒有缺值 (**NA** 的 gene (共挑 5 個)
3. 為這 5 個 gene **各畫一張** scatter plot 表現量隨時間點變化)
4. 用 `rainbow()` 或自訂色系上色，並加上 legend

上色規則：這份資料的 77 個欄位分屬數種**實驗條件**，每種條件底下是一系列時間點 (`alpha 18` 欄 / `cdc15 24` 欄 / `cdc28 17` 欄 / `elu 14` 欄 / `cln3 2` 欄 / `clb2 2` 欄)。同一個實驗條件的所有時間點用同一種顏色，不同條件用不同顏色。

提示

```
cyc <- read.delim("cycleData_peak.txt")
peak <- cyc$peak
expr <- as.matrix(cyc[, 2:(ncol(cyc) - 1)]) # 中間 77 欄為表現量
n_na <- apply(expr, 1, function(x) sum(is.na(x)))
# n_na == 0 的列就是沒有缺值的 gene 本份資料共 72 個 )
```

```
# 取實驗條件：注意不能只用 sub("[.0-9]+$", "", ...)  
# 那會把 cdc15 與 cdc28 併成同一組 "cdc"  
cond <- sub("^(alpha|cdc15|cdc28|elu|cln3|clb2).*", "\\1", colnames(expr))  
table(cond)  # alpha 18 / cdc15 24 / cdc28 17 / elu 14 / cln3 2 / clb2 2
```

cdc15 和 cdc28 是**兩個不同的實驗條件**，欄名都以 cdc 開頭。若用「去掉尾端數字」的寫法會把它們併成一組，顏色就少一種——這點要小心。

一定要挑沒有缺值的 gene，有 NA 的話畫出來會斷點。全 800 個 gene 中沒有缺值的只有 **72 個**，各期別分別是 G1 30 / G2M 19 / M/G1 10 / S/G2 10 / **S 只有 3 個** —— S 期可挑的很少，記得先篩再挑。